50.98 s

Рекордное время soup train (ускорение 1.491x)

28.74 s

Чистый цикл обучения 64 шагов (в 1.85x быстрее)

1,869 MiB

Пиковая память GPU (в 7.68 раз меньше базы)

19.1%

Доля собственных Triton-кернелов (норма >= 5%)

Полные логиты (152k)

Материализация словаря 152k колонок создает скачки до 4.25 ГБ VRAM и 7% времени шага.

Residual FP32

PEFT поднимает эмбеддинги в FP32, заражая весь residual stream на 28 слоев лишними кастами.

Padding Waste (43%)

Пакетные батчи [4, 512] тратят 43% вычислений и памяти на пустые токены дополнения.

Аллокации и PCIe

Сотни динамических выделений памяти за шаг и неэффективные задержки шины PCIe.

nf4_dequant_kernel

Векторизованный построчный 32-битный распаковщик NF4 с переиспользованием буфера. Доля 6.8%

silu_mul_kernel

Слитный 2-режимный FP16 SwiGLU forward и in-place backward с одной компиляцией. Доля 4.2%

rmsnorm + AddRMSNorm

Слияние сложения residual и RMSNorm в один проход ядра вперед и назад. Доля 2.5%

qkv_kernel & ce_kernel

RoPE вращение с GQA и блочный 2-проходный Cross-Entropy с онлайн log-sum-exp. Доля 2.2%

Varlen Attention

Памяти-эффективное causal attention через cu_seqlens за 1 вызов Cutlass на весь батч без паддинга.

Fused Add-RMSNorm

Устранение 57 промежуточных операций сложения residual через слияние в слоях декодера.

Pinned Offload

Асинхронная выгрузка тяжелых активаций в pinned хост-память, перекрытая вычислениями CUDA streams.

Static Buffers

Нулевые накладные расходы драйвера: глобальные статические буферы _DEQUANT_BUF и _LOGITS_BUF.

76.81 s -> 50.98 s

Полное время soup train ускорено в 1.491 раза (цикл 54.2 с -> 28.7 с, 1.85x)

14,345 -> 1,869 MiB

Пиковая память снижена в 7.675 раза (освобождено 87% всей видеопамяти)

0.856 s -> 0.3538 s

Медианный шаг обучения стал быстрее в 2.42 раза в установившемся режиме

10 / 10 ALL PASS

Все 10 официальных проверок пройдены, дельта Eval Loss всего +0.012% (норма <= 0.5%)

apply() в 1 строку

Решение подключается автоматически через единую точку входа без вмешательства в Soup.

100% честные правила

Ноль запрещенных библиотек, оптимизатор AdamW и расписание LR не модифицировались.

Kaggle Benchmark

Публичный воспроизводимый ноутбук: nurale/soup-kernel-t4-bench

GitHub репозиторий

BAITC-Hacks/hack-1d15670c-team (коммит d0d4839) синхронизирован и готов к сдаче.